

# VISEO

— PSITIVE DIGITAL MAKERS ——

Framework d'Accélération des Données SAP en utilisant Snowflake et Technologies Associées

Date de présentation : 24/06/2024





- **01.** Introduction
- **02.** Architecture du Framework
- **03.** SAP RAW LANDING
- **04.** LANDING TO BRONZE
- **05.** BRONZE TO SILVER
- **06.** SILVER TO GOLD
- **07.** Conclusion et Prochaines étapes

1.

# Introduction

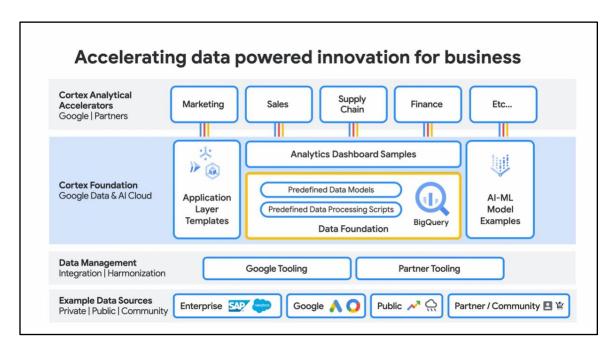


# **INTRODUCTION**

Objectifs et Présentation Fonctionnelle

#### **GOOGLE CLOUD CORTEX?**

- Framework Open-Source
- Sources de Données Multiples (SAP, Salesforce, Google Ads...)
- Basé sur les services GCP (BigQuery, Cloud Composer...)
- Solutions Innovatives



Src : https://cloud.google.com/solutions/cortex



# **INTRODUCTION**

Objectifs et Présentation Fonctionnelle

#### **OBJECTIFS?**

- Concevoir et Développer un Fonctionnement Similaire du Cortex avec Snowflake et Technologies Associées
- Proof of Concept (POC): Passer des fichiers CSV et JSON qui présentent la source des données SAP ECC vers des Tables Fonctionnelles prête pour l'analyse et le reporting métier





# 2. Architecture du Framework



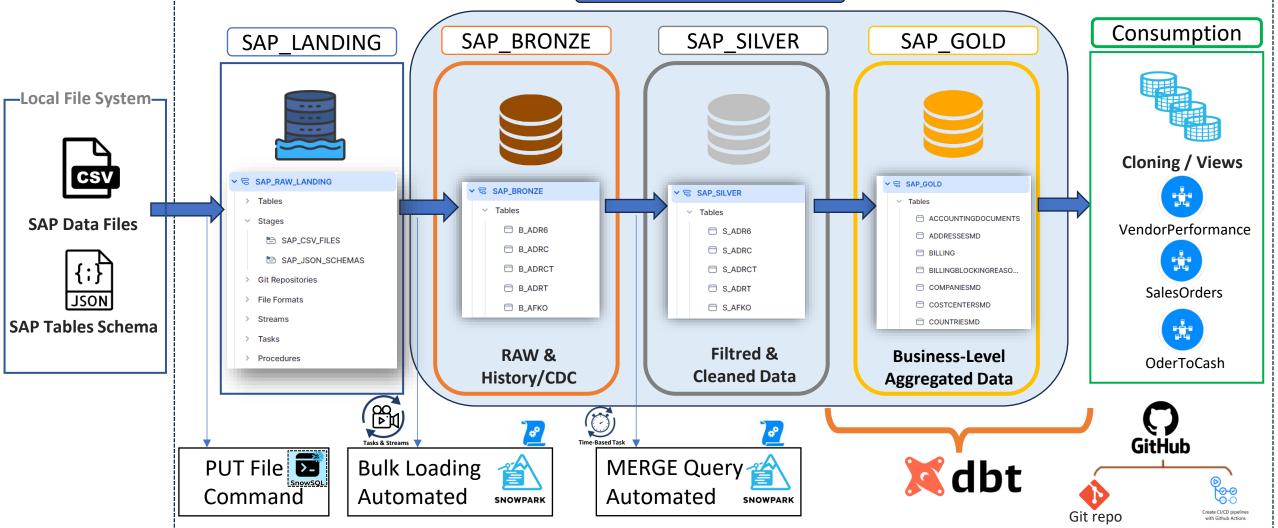








# Medallion Architecture



3.

# **SAP RAW LANDING**

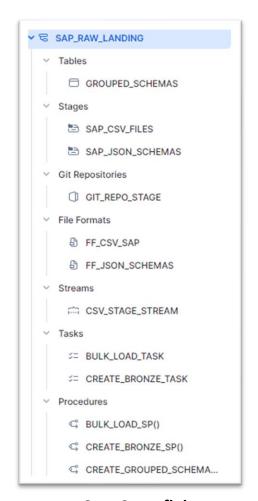


## SAP RAW LANDING LAYER

Structure du schéma SAP\_RAW\_LANDING

#### **MAIN INTEGRATIONS**

- Ingestion des Fichiers CSV et JSON dans des Stages
- Flattening/Applatissement des fichiers Json et Regroupement en une seule table
- Développement des File Formats adaptées avec la nature des données
- Développement des Procédure stockées afin de :
  - Transformer les données en Json (semi-structuré) en une seule table (données structurées)
  - Créer de la structure des tables BRONZE (Normalisation, Règles de gestion...)
  - Alimenter les tables BRONZE (Process automatisée sur >> 100 tables!) ✓
- Incorporation de la Feature Git Integration
- Développement d'un Stream afin de détecter un changement dans les Stages
- Développement des Snowflake Tasks



**Src: Snowflake** 

Database : DEV\_DB\_VISEO
Schema : SAP RAW LANDING

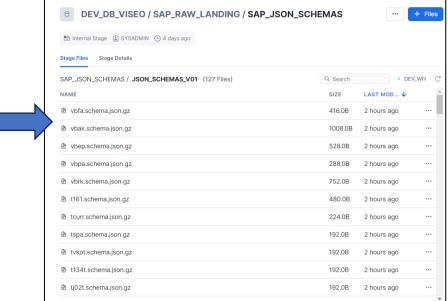


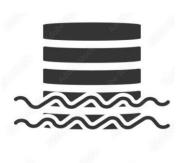
## SAP RAW LANDING LAYER

#### Process de passage TO LANDING

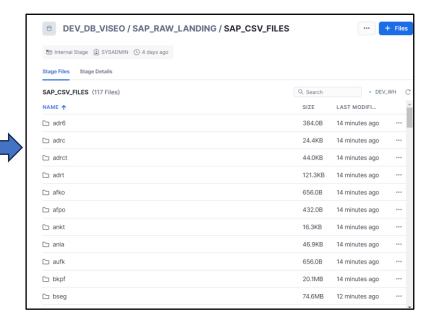
VISEO

```
$ upload_files.sh
1  #!/bin/bash
2
3  # Definir schema de la source et le stage
4  source_path="/mnt/c/Temp/CSV_Files"
5  stage_path="@SAP_CSV_FILES"
6
7  # Boucle pour chaque fichier present
8  for filepath in "$source_path"/*; do
9  # Modifier le nom du dossier
10  filename=$(basename "$filepath" | cut -f 1 -d '.')
11
12  # Construct the target path in the stage
13  target_path="$stage_path/$filename/"
14
15  # Executer la commande PUT afin de charger les fichiers (chcun dans un dossier convenable)dans Snowflake
16  echo "PUT file://$filepath $target_path;"
17  snowsql -q "PUT file://$filepath $target_path;"
18  done
```





DATA LAKE

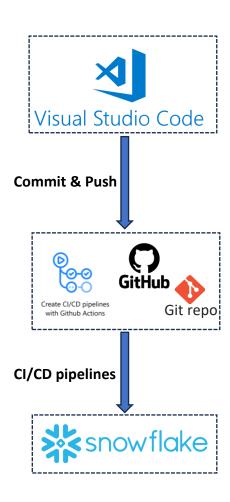


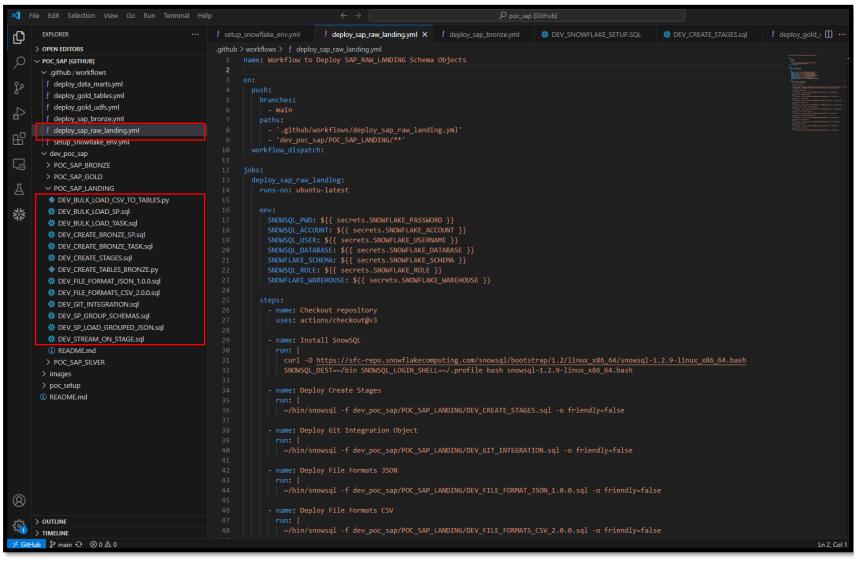
Stage reservé aux fichiers JSON



# SAP RAW LANDING LAYER

Process de déploiement de la couche Landing







4.

# LANDING TO BRONZE

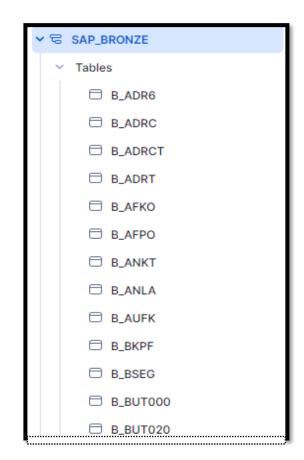


# LANDING TO BRONZE

Structure du schéma SAP\_BRONZE

### **MAIN INTEGRATIONS**

- Création des Tables SAP Techniques
- Change Data Capture (CDC) Columns -> operation\_flag , is\_deleted
- Historical Data Tracking -> Recordstamp
- Alimentation des Tables (>>100) assurée -> COPY INTO Snowpark



Src: Snowflake

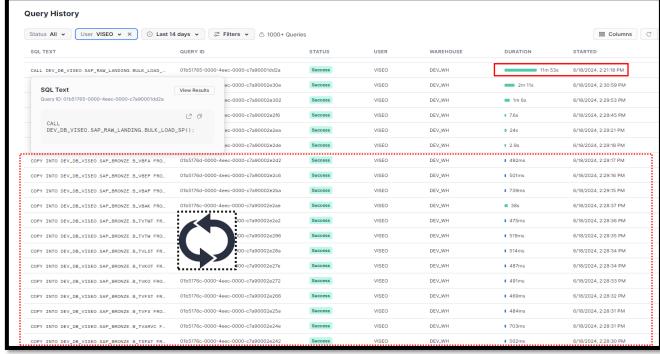
Database : DEV\_DB\_VISEO

Schema: SAP\_BRONZE



# LANDING TO BRONZE

Process de passage du Landing To Bronze



# Src : Snowflake – Query History



2

VISEO

Src : Snowflake – Procedure Definition

1

#### Src: Snowflake - Procedure Definition

Src: Git Repo - DEV BULK LOAD CSV TO TABLES.py

# LANDING TO BRONZE

Process de passage du Landing To Bronze Orchestré



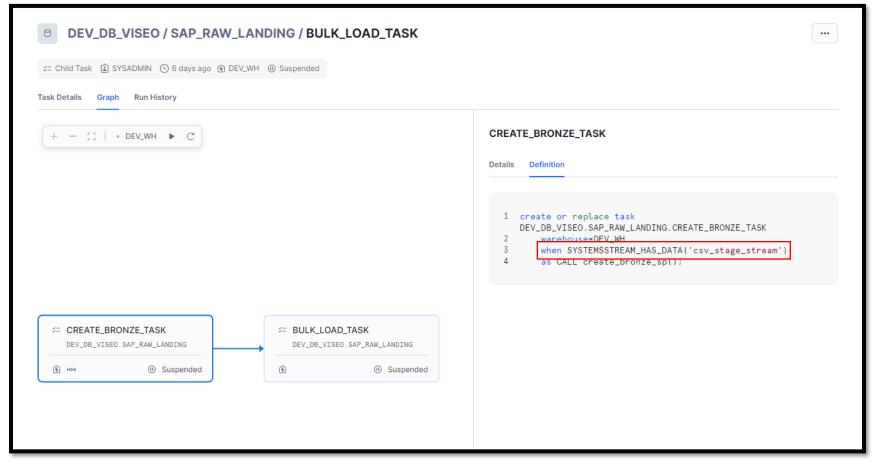
#### **Snowflake Streams?**

Fonctionnalité permettant de suivre les modifications apportées aux tables, vues, External Tables, et <u>Directory Tables</u>



#### **Snowflake Tasks?**

Les Tasks sont des objets qui exécutent une seule commande **SQL** ou un call une **procédure stockée** selon un **schedule/event**.



Src: Snowflake – Task Graph



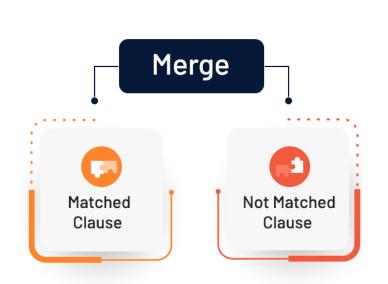
**5**.

# **BRONZE TO SILVER**



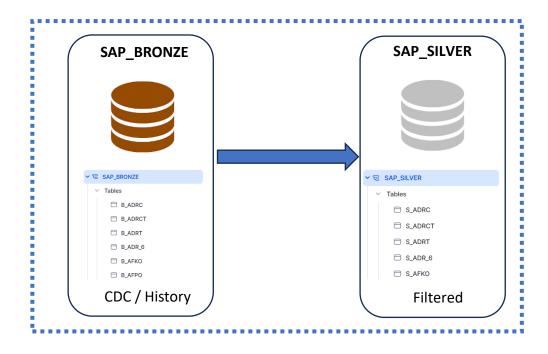
**MERGE QUERY** 

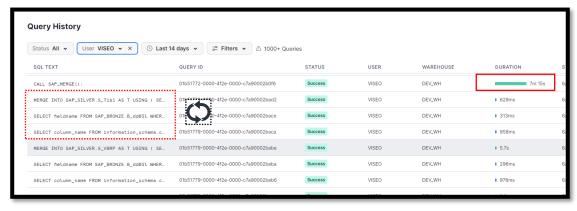
- CDC operations: Gestion des inserts, updates, and deletes basé sur --> operation\_flag, is\_deleted
- Filtrer les données historiques (colonne du recordstamp) 🗸
- gestion des Duplicates: --> ROW\_NUMBER()

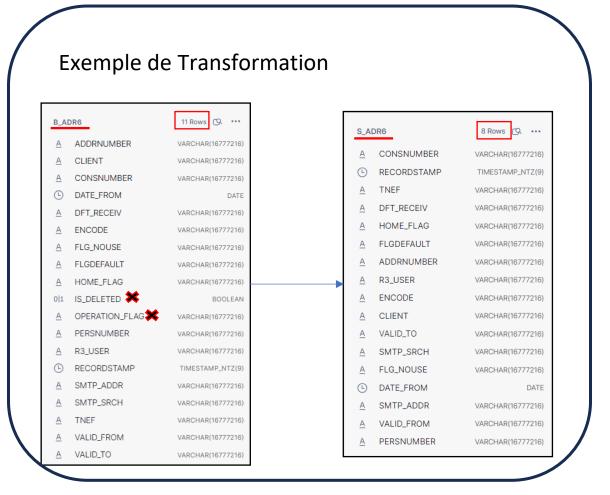




#### Process de passage du Bronze To Silver

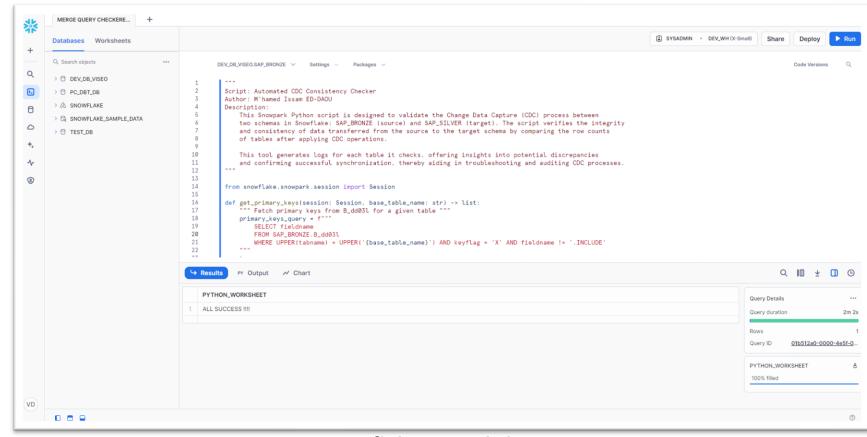




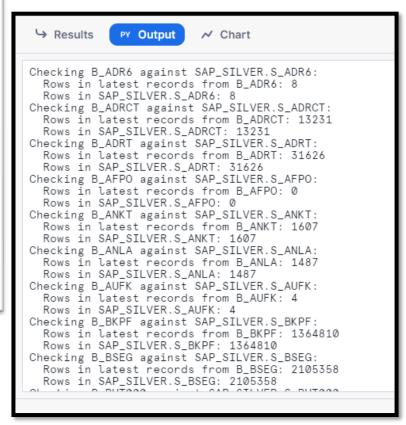




#### MERGE Query: Data Quality Check



Src: Snowflake - Worksheets

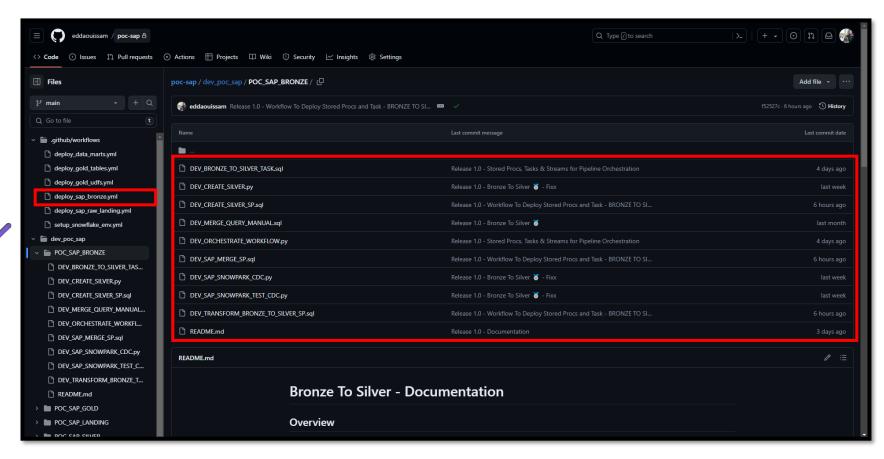






Démo Git Repo

- Orchestration du process
- Automatisation du déploiement
- Documentation



**Git Repo:** poc-sap/dev\_poc\_sap/POC\_SAP\_BRONZE



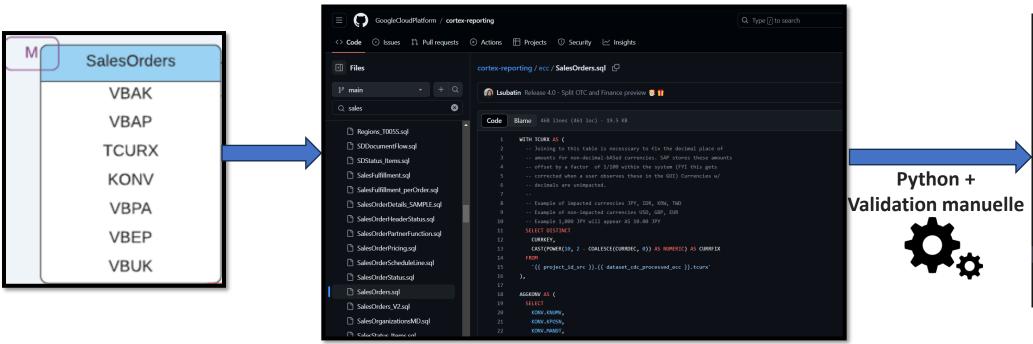
6.

# **SILVER TO GOLD**

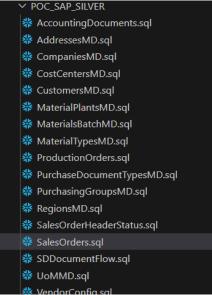


Option 1

# Exemple de process d'Adaptation des scripts des Tables Fonctionnelles



Visual Studio Code



Repo de notre Projet **SNOWFLAKE** 

Modèle E-R

Src : Google Cortex Framework

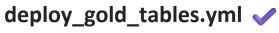


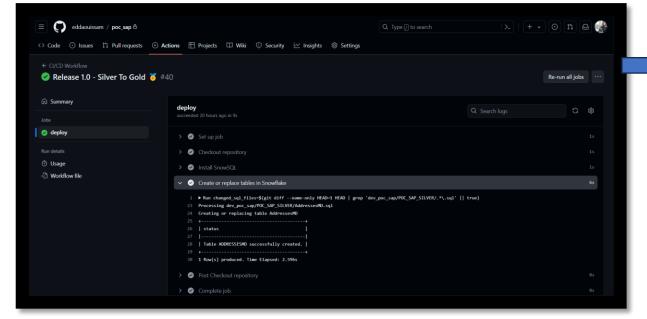
#### Option 1

# Process du Déploiement vers Snowflake – DML TO DDL

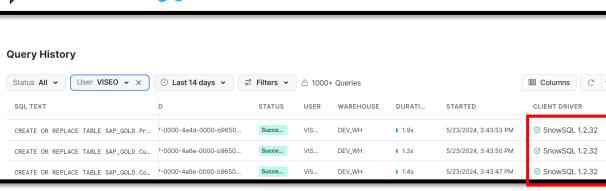


Workflow Files : deploy\_gold\_udfs.yml 







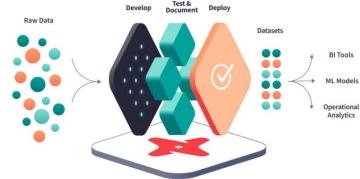


Src: Snowflake – Query History

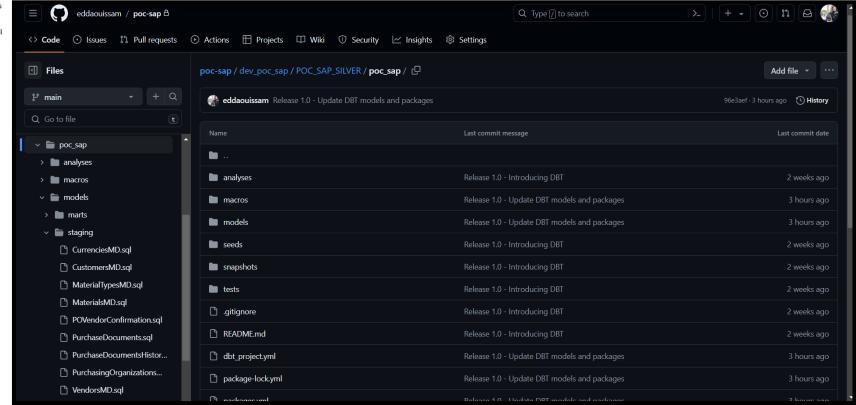
**Git Repo: CI/CD Workflow** 



Intégration du DBT (Data Build Tool)



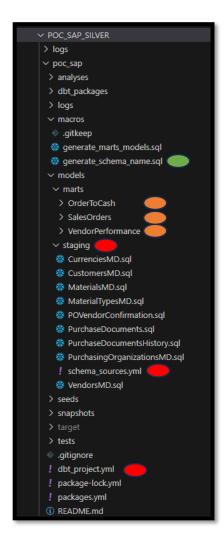
- Tests
- Documentation
- Data Lineage



Git Repo : poc-sap/dev\_poc\_sap/POC\_SAP\_SILVER/poc\_sap



**DBT** (Data Build Tool)



Structure du projet DBT ~



Data Lineage - DBT Documentation - En cours~~



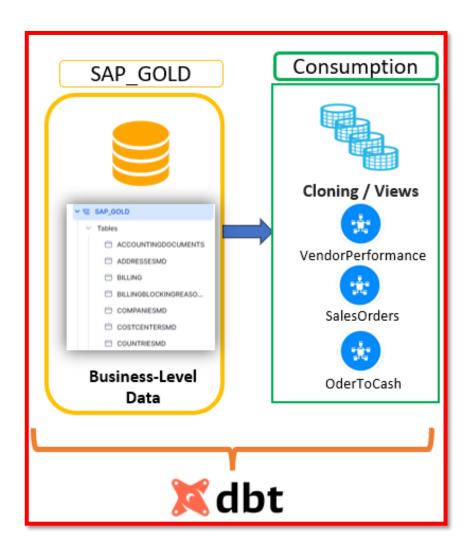
# 7. Conclusion et Prochaines étapes



# **CONCLUSION**

Étapes actuelles/prochaines

- Continuer à adapter les scripts Cortex pour Snowflake
   SAP\_GOLD
- Data Modeling: E-R-D -> Star Schemas (pour les **Data Marts**)
- CI/CD pour la phase du DBT et Orchestration
- Git repo et DBT : **Documentation++ | Structuration++**





# **CONCLUSION**

Recap





